

Trabajo Final Inteligencia de Negocios 2025

Remanente octubre-2025

Maestría en Economía Aplicada, Facultad de Ciencias Económicas de la Universidad de Buenos Aires

Condiciones de Entrega

- a) La fecha límite de entrega es el domingo 16 de noviembre a las 23:59:59.
- b) Deben enviar una un archivo .ipynb (notebook de jupyter o colab) con el formato tp_final_bi_2025_{apellido}.ipynb. Ejemplo: si el alumno se llamase Juan Pérez, debe enviar el archivo tp_final_bi_2025_perez.ipynb.
- c) Este archivo debe ser adjuntado en un correo electrónico a fmastelli@gmail.com con el asunto "TP final REMANENTE OCTUBRE bi 2025 {apellido}". Ejemplo: si la alumna se llamara Marta Calvo, debe enviar el email con el asunto "TP final REMANENTE OCTUBRE bi 2025 Calvo".
- d) El archivo que adjuntan en el mail debe estar totalmente ejecutado sin errores. Debe contener tanto el código como las explicaciones.

Conjunto de datos

- a) Contarán con 1 dataset de viajes de UBER:
 - o [uber csv](#)
 - o Para mayor información puede recurrir [a la fuente](#)

Consignas

- 1) Lea el archivo "uber.csv". ¿Qué puede decir acerca de la estructura del dataset? Mencione cantidad y tipos de columnas, datos faltantes, de qué va el conjunto de datos en términos generales.
- 2) Análisis exploratorio
 - a) Genere una variable de distancia de recorrido, para ello debe tener en cuenta la geolocalización de partida (pickup_longitude, pickup_latitude) y la geolocalización de llegada (dropoff_longitude, dropoff_latitude). Ver [fórmula de semiverseno](#) (vale dialogar y apoyarse en la IA generativa para la implementación o el uso de librerías que lo resuelvan de manera directa, por supuesto).
 - b) Obtener la matriz de correlaciones para las variables numéricas . ¿Qué puede decir acerca de la correlación entre la tarifa (fare_amount) y la distancia de recorrido ? Por default la correlación se reporta con el método de Pearson, ahora vuelva a generar la matriz pero con el método de spearman. ¿Qué diferencias encuentra? ¿A qué se puede deber?
 - c) Obtener estadísticas descriptivas para la variable target (fare_amount) y realizar un histograma de la misma. Comente los resultados obtenidos
 - d) Graficar un scatterplot de la variable price y la distancia de recorrido. ¿Detecta alguna anomalía?
 - e) Eliminar los outliers univariados de las variables fare_amount y distancia de recorrido. Utilizar y fundamentar el o los criterio/s y métodos que consideren

adecuados. Deberá trabajar con este dataset filtrado en lo que resta del Trabajo Práctico

- f) Vuelva a realizar la matriz de correlaciones y el histograma de la variable fare_amount. Comente los cambios observados si los hubiera.

3) Partición de data

- a) Genere un dataset de entrenamiento y otro de test usando split de 80% y su Número de Documento como random_state.

4) Modelado tradicional

Durante esta consigna, **puede generar las transformaciones que considere conveniente sobre las variables.**

- a) Ajuste un modelo lineal sobre el dataset filtrado de entrenamiento.
 - i) ¿Qué puede concluir e interpretar acerca del signo y tamaño de los coeficientes?
 - ii) ¿Qué puede decir acerca de la significatividad estadística de los mismos?
- b) Ahora ajuste un modelo lineal LASSO (previa estandarización/normalización de variables), optimizando el parámetro de penalización (lambda en nuestra clase teórica, alpha en sklearn). ¿Alguna variable quedó eliminada? Comente.

5) Modelos de Aprendizaje

Durante esta consigna, **puede generar las transformaciones que considere conveniente sobre las variables.**

- a) Random Forest: Realice búsqueda de hiperparámetros (puede usar conjunto de validación o validación cruzada) sobre el dataset de entrenamiento y obtenga un mejor modelo. Reporte métricas de validación (rmse, mae).
- b) Boosting: Realice búsqueda de hiperparámetros (puede usar conjunto de validación o validación cruzada) sobre el dataset de entrenamiento y obtenga un mejor modelo. Reporte métricas de validación (rmse, mae).
- c) Redes Neuronales: ídem. Puede probar al menos 3 arquitecturas diferentes variando la cantidad de capas y neuronas de la red densamente conectada (Dense en keras).

6) Performance

- a) Evalúe la performance de todos los modelos (lineal por MCO, LASSO, Random Forest, Boosting y Redes Neuronales) sobre el conjunto de datos de test.. Reporte RMSE y MAE. Concluya